

基于自监督学习与跨模态注意力的石榴病害时序演变 视觉识别与预测

摘要

本文面向石榴果实病害的智能识别与预测需求，基于连续采集的果实时序图像与园区气象观测数据，构建兼顾病害视觉识别、气象关联分析、阶段预测及浅层机械损伤检测的多模态综合方法。

针对任务一：病害阶段识别，本研究提出融合多策略自监督预训练 **SimCLR**、**BYOL** 与 **ConvNeXt V2-Swin Transformer** 混合主干的 **SSF-Net** 模型，通过卷积与 Transformer 协同表征局部纹理和长程依赖，并在微调阶段引入气象特征实现早期多模态交互，实现健康期、初发期与发病期的自动划分。实验表明，模型在测试集上的准确率、F1 值和 Kappa 系数均达到 **1.000**，显著优于 ResNet-50 与 ViT 等基线网络，验证了方法在细粒度病害识别上的高精度与强大性能，最终使用 **SSF-Net** 模型计算相关结果。

针对任务二：在病害-气象关系建模上，本研究利用 **Spearman** 相关分析、有序 **Logit** 回归与 **LightGBM** 模型，对温度、湿度、太阳辐射等关键气象因子进行多尺度定量分析。结果表明，病害进展与高温、高湿（低 VPD）、降水增强显著正相关，且前 1-2 周气象条件存在明显滞后效应；**LightGBM** 模型准确率达 **0.918**，特征重要性分析显示温度、露点温度和蒸汽压差是驱动病害演化的主要环境因子。

针对任务三：在病害阶段预测中，本研究构建知识蒸馏增强的跨模态时序 **Transformer** 架构，融合视觉特征与气象序列，引入多头交叉注意力、VL-T5 式视觉-气象表示交互及时间卷积网络以强化局部时序建模，并通过动态课程学习与蒙特卡洛 **Dropout** 进行量化不确定性。结论表明：模型在未来四周病害阶段预测任务中验证集准确率稳定在 **0.90** 以上，对健康期与发病期的预测精度较高，多模态时序建模在病害早期预警中的应用潜力巨大。

针对任务四：在浅层机械损伤检测中，本研究针对果实表面线性划痕易与病斑混淆且缺乏精确标注的问题，设计结合半监督 **GAN** 异常检测、**U-Net** 边缘分割与形态学分析，**Canny** 边缘检测与霍夫变换的多尺度线性结构增强框架，通过多尺度注意力与对比学习预训练提升对细长划痕的敏感度，综合重构误差、线性度评分与异常指标构建机械损伤分数与病害分数联合判决准则。结论表明：在 2659 张图像的应用中，该方法能够有效筛选具有浅层机械损伤的果实样本，注意力热力图准确聚焦划痕区域，并在高分样本中显著抑制病害误判，体现出良好的模型性能。

本文将自监督学习、多模态特征融合、时序建模和异常检测等技术有机整合，系统解决了石榴果实病害的阶段识别、气象驱动机制解析、发展趋势预测及浅层机械损伤区分四个关键问题。

关键词：石榴果实病害；时序图像；多模态；SSF-Net；Transformer

目 录

基于自监督学习与跨模态注意力的石榴病害时序演变视觉识别与预测	1
摘要	1
1 问题重述	3
1.1 研究背景	3
1.2 任务提出	3
2 任务分析	3
2.1 任务一：果实病害阶段视觉识别与量化。	3
2.2 任务二：病害阶段与气象因子的相关性分析	3
2.3 任务三：基于多模态数据的病害阶段预测模型构建	4
2.4 任务四：浅层机械损伤识别	4
3 模型假设	4
4 数据探索性可视化分析	5
5 任务一的模型建立与求解	7
5.2 自监督预训练与混合 Transformer 架构建立	7
5.2.1 自监督预训练框架	7
5.2.2 混合 Transformer 架构	8
5.2.3 微调阶段与多模态特征融合	8
5.2.4 基线模型与消融实验设计	8
5.3 果实病害阶段视觉识别与量化求解结果	9
6 任务二的模型建立与求解	11
6.1 果实病害阶段与气象因子的定量关系建模	11
6.2 果实病害阶段与气象因子的定量关系求解结果	12
7 任务三的模型建立与求解	15
7.1 基于多模态数据的病害阶段预测模型构建	15
7.1.1 多模态融合与交叉注意力机制	15
7.1.2 视觉-语言 Transformer (VL-T5) 设计思想	16
7.1.3 增强局部时序模式捕捉能的时序建模	16
7.2 病害阶段预测模型的求解	16
8 任务四的模型建立与求解	19
8.1 基于生成对抗网络与形态学分析结合的病害检测框架	19
8.1.1 基于半监督 GAN 的异常检测框架	19
8.1.2 基于 U-Net 的边缘分割与线性特征提取	19
8.1.3 融合多个异常指标	20
8.2 生成对抗网络与形态学分析结合的病害检测框架求解	20
9 总结	22
10 参考文献	24
11 附录	25

1 问题重述

1.1 研究背景

石榴 (*Punica granatum* L.) 作为我国西北干旱半干旱地区重要的特色经济果树, 在促进区域经济发展和农民增收方面发挥着重要作用。在其生长周期中, 石榴果实易受到炭疽病、褐斑病、疮痂病等多种病害的侵袭, 导致果实品质下降和产量损失, 严重制约石榴产业的可持续发展。传统病害识别与监测主要依赖农业专家的田间观察和经验判断, 这种方法不仅主观性强、效率低下, 而且难以实现病害的早期发现和精准预警。在规模化种植园区, 病害的传播速度快、影响范围广, 传统人工监测方式已无法满足现代精准农业的需求。

1.2 任务提出

任务一: 果实病害阶段的视觉识别与量化分析。基于时序图像数据, 定义石榴果实的病害发展阶段 (健康期、初发期、发病期)。通过对附件 1 中提供的果实图像进行视觉特征提取, 实现对果实病害阶段的自动划分。结果需按照表 1 格式整理, 并保存为 `result1.xlsx` 文件。

任务二: 病害阶段与气象因子的相关性分析。结合任务一中所划分的果实病害阶段, 整合附件 2 中提供的微气候观测数据, 系统分析并量化关键环境因子 (温度、湿度、太阳辐射) 与病害发展阶段的统计关联性。

任务三: 基于多模态数据的病害阶段预测模型构建。融合图像视觉特征与气象因子, 构建一个综合预测模型, 用于判断果实病害的发展趋势。利用附件 3 中提供的时序图像数据, 预测目标果实在未来四周内的病害阶段, 结果按表 2 格式整理并保存为 `result3.xlsx`。

任务四: 浅层机械损伤的识别与区分。设计并实现一种识别算法, 用于检测石榴果实表面的浅层机械损伤 (划痕)。该类损伤在形态上呈线性、随机分布, 且不伴随病害典型特征 (斑点、霉层、腐烂)。算法需基于附件 1 的图像数据, 识别出具有浅层机械损伤的果实, 结果按表 3 格式保存为 `result4.xlsx`。

2 任务分析

2.1 任务一：果实病害阶段视觉识别与量化。

本研究采用多策略自监督预训练与混合 Transformer 的细粒度分类框架。在自监督预训练阶段, 同时引入 SimCLR 和 BYOL 两种方法进行对比, 通过负样本对比与无负样本两种范式提升模型鲁棒性。主干网络采用 ConvNeXt V2 与 Swin Transformer 的混合架构, 利用 ConvNeXt 提取局部纹理特征, Swin Transformer 捕获长程依赖关系。在微调阶段, 结合提示微调与多模态特征融合, 将初步气象特征与视觉特征进行早期交互。基线模型选择 ResNet-50 作为传统深度学习代表, ViT 作为 Transformer 架构代表。评估指标包括 Accuracy、F1-score 和 Kappa 系数。

2.2 任务二：病害阶段与气象因子的相关性分析

本研究以任务一得到的果实病害阶段为因变量, 旨在定量刻画附件 2 多维气象因子对“健康期→初发期→发病期”演化的方向与强度。方法上, 先按周尺度将逐时气象聚合 (数值取周均、`weather_desc` 取众数), 与样本周次对齐并将阶段有序编码为 0/1/2; 完成缺失处理、标准化与共线诊断后, 以 Spearman 与互信息进行非参数筛查, 再以有序 Logit 和 LightGBM 为主模型检验比例优势假设, 必

要时采用部分比例优势或多项 Logit 替代，报告系数、置信区间与边际效应，并绘制阶段概率曲线。通过 Bootstrap 与按树/按周分层等稳健性分析及聚合口径敏感性检验，确保结论可靠，最终给出关键环境因子排序与阈值区间，为监测预警与田间干预提供定量依据。

2.3 任务三：基于多模态数据的病害阶段预测模型构建

本研究提出知识蒸馏增强的跨模态时序 Transformer 架构。在多模态融合阶段，采用多头交叉注意力机制实现视觉特征与气象特征的深度交互，同时引入视觉-语言 Transformer (VL-T5) 的设计思想，将气象数据视为“文本”序列进行处理。时序建模部分，在标准 Transformer 基础上加入时间卷积网络 (TCN) 模块，增强局部时序模式捕捉能力。训练策略上，采用动态课程学习，根据预测难度自适应调整训练样本顺序，并结合蒙特卡洛 Dropout 与贝叶斯神经网络进行双重不确定性量化。通过以上多模态与预测模型的构建，本研究通过模型损失、准确率、混淆矩阵，以及文本数据的特征重要性进行可视化，综合评判模型性能，最终输出任务三所需表格保存到 results3.xlsx 文件，该文件将作为支撑材料上传。

2.4 任务四：浅层机械损伤识别

本研究针对传统方法对线性特征敏感度不足的问题，基于多尺度注意力机制提供解决方法。该方法采用多尺度特征金字塔网络提取多层次特征表征，结合自注意力机制强化损伤区域响应，并通过 SimCLR 对比学习预训练在无标签条件下学习判别性特征表示。模型架构以 ResNet-FPN 为骨干网络，集成通道注意力与空间注意力模块，构建对比学习预训练框架，最终融合多尺度特征响应、注意力权重分布和相似度评分进行异常判断。创新性地将多尺度特征融合增强小损伤检测能力、自注意力机制实现精准定位以及对比学习预训练提升无监督特征判别力融合。输出包括完整的损伤检测数据表格，多尺度特征图、注意力热力图、特征空间分布和 ROC 曲线等多维度可视化分析，同时提供 Precision、Recall、F1-score 和 ROC-AUC 等量化评估指标，确保检测结果具有充分的科学性和可解释性。

3 模型假设

考虑到实际情况以及为了简化模型计算，本研究针对本次解题提出如下几点假设：

(1)、假设与直接从零训练或有监督预训练相比，采用 SimCLR 与 BYOL 进行多策略自监督预训练，并结合 ConvNeXt V2 (局部特征) 与 Swin Transformer (全局依赖) 的混合主干网络，能够学习到更具判别力的视觉表征，从而在石榴果实病害的细粒度分类任务上取得更高的准确率。

(2)、假设石榴病害从“健康期→初期→发病期”的演进，并非由气象因子的简单线性变化引起，而是当关键因子达到特定阈值或区间时，会显著增加病害阶段升级的风险概率，且这种效应可以通过有序 Logit 模型中的边际效应进行定量刻画。

(3)、假设与仅使用视觉特征或简单拼接多模态特征的模型相比，采用多头交叉注意力机制进行深度特征融合，并嵌入时间卷积网络 (TCN) 以增强局部时序建模能力的 Transformer 架构，能够更充分地利用历史信息，在预测未来病害发展阶段时表现出更低的预测误差和更高的序列准确性。

(4)、假设浅层机械损伤在图像上表现为高线性特征和与正常模式的高重构误差，而病害则表现为纹理/颜色的局部异常。通过半监督 GAN 计算的重构误

差，结合 U-Net 与霍夫变换提取的形态学线性度评分，进行多特征融合决策，能够高精度地将两者区分开来，避免误判。

4 数据探索性可视化分析

由于数据文件的分布文件夹较多，层次复杂，且图像数据较大，本研究为能够在解题之前，对数据有一个详细的理解和准备，对此对数据进行多维度的探索性可视化分析，得到结果如下：



图 4.1 原始数据预览

本研究首先对数据进行展示，从获取的八张图片来看，石榴的拍摄图像清晰。每张图片均以单个石榴果实为主体，拍摄角度较为一致，均为近距离拍摄；部分图片中可见人工手持果实或白色标牌（用于编号或标识），照条件自然。

表 4.1 石榴图像数据基本统计特征

统计指标	数值
总图片数量	2,659 张
监测周期	14 周
监测树木	10 棵
平均每周图片数	189.9±12.3 张
数据采集密度	高密度时序监测

本研究对石榴图像数据进行详细的统计分析，结果如表 4.1 所示。数据集中共计收集 2,659 张图片，显示每棵树在不同周次的生长与果实发育情况。检测 10 棵树且周期达到 14 周，具有较强的时序数据特征，且数据的高密度时序监测特点，每周的图像采集都具有较高的频次和密度，能够有反应石榴树在监测周期内的细微变化。




图 4.2 石榴图像数据时间序列分析

图 4.2 包含四个子图，图 A) 为每周的总图片数量变化趋势。曲线呈现出一定的下降趋势，B) 主要树木图片数量趋势，该图为几棵主要树木在各周次的图片采集情况。从图中可以看到，某些树木的采集量在前几周增长较快，而在后期逐渐趋于平稳或下降。C) 累积图形随着时间推移，图片数量的累积增长情况。以逐渐递增的方式可视化监测期内的总数据量，数据采集稳定增长。D) 通过展示每周图片数量的 3 周移动平均，分析数据的平滑趋势。移动平均线与原始数据相比，能有效去除短期波动，展现出更平滑的趋势。




图 4.3 石榴数据组成结构与模式分析

图 4.3 对石榴图像数据的组成结构及其模式进行了分析，包含了四个不同的子图，A) 总体组成分布中，能够清晰显示各树在总图片数量中的占比。该图为不同树木在监测周期内的拍摄频率差异，B) 各树图片数量分布，从图中可以观

察到，不同树木的图片采集数量存在差异，标号 07 采集量远高于其他树木。C) 累积分布函数通过观察图形的上升曲线，可以评估数据在不同树木之间的分布情况。从图中可以看出，CDF 曲线在初期阶段呈现出较为平缓的上升趋势，大多数图像集中在少数几棵树木上，而其他树木的图像数量则相对较少。D) 各树木累计图片数量图中同样可见不同石榴树的采集图片数量差异较大、




图 4.4 石榴数据分析与关联性

图 4.4 包含四个子图，分别展示石榴数据的关联性分析与模式研究。A) 该热力图为不同周次与树木之间的相关性强度。从图中可以观察到，M1 和 M2 的相关性值较高，这些树木在这两个周次的图像采集频率或分布特征较为相似。M3、M4 与其他树木的相关性较低，这些树木在不同周次的图像变化特征较为独立。B) 极坐标图为各树木图片数量的分布特征。部分树木的图像数量分布在某些特定周次较为集中，M1 和 M5 在早期周次的图片数量较多，其他树木在后期周次呈现出更高的采集频率。C) 该堆叠面积图通过逐周展示不同树木的图像数量变化及其累积贡献。M1 和 M2 在前期周次的图片数量贡献较大，其他树木的采集量则在后期逐渐增加。D) 树木相关性矩阵可见各树木之间图片数量的相关性。从结果来看，M1 与 M2、M3 与 M4 之间的相关性较高。M5 和 M6 相关性较低。

5 任务一的模型建立与求解

5.2 自监督预训练与混合 Transformer 架构建立

本研究的目标是在数据稀缺或标注困难的场景下，利用自监督预训练与混合 Transformer 架构进行果实病害阶段的视觉识别与量化。接下来本研究将提供详细的理论模型。

5.2.1 自监督预训练框架

本研究自监督预训练框架使用 SimCLR 和 BYOL 两种方法进行对比，以提升模型性能。

SimCLR: 对比学习方法，通过最大化相似样本之间的相似度，最小化不同

样本之间的相似度。通过学习一个可以将图像映射到低维空间的表示，使得相似图像的表达更接近，而不同图像的表达更远。公式如下：

$$\mathcal{L}_{\text{SimCLR}} = -\log \frac{\exp(\mathbf{z}_i^\top \mathbf{z}_j / \tau)}{\sum_{k=1}^{2N} \exp(\mathbf{z}_i^\top \mathbf{z}_k / \tau)} \quad (1)$$

BYOL: 与 SimCLR 不同，BYOL 不使用负样本，而是通过构造正样本对来进行训练，通过最小化源和目标图像的距离，进而进行自监督学习。公式如下：

$$\mathcal{L}_{\text{BYOL}} = \frac{1}{2} (\|\mathbf{z}_i - \mathbf{z}_j\|^2) \quad (2)$$

5.2.2 混合 Transformer 架构

本研究使用 ConvNeXt V2 和 Swin Transformer 的混合架构来提取图像特征：

ConvNeXt V2: 一个现代化的卷积网络，用于提取图像的局部纹理特征。

ConvNeXt V2 结构的核心思想是通过卷积操作在局部区域内捕捉细节信息。

在特征提取时，ConvNeXt V2 使用标准卷积操作来从图像中提取局部特征：

$$\mathbf{f}_{\text{local}} = \text{Conv}(\mathbf{I}) \quad (3)$$

Swin Transformer: 在捕获局部特征的基础上，使用 Swin Transformer 来捕获图像的长程依赖关系。Swin Transformer 基于窗口注意力机制来处理长程信息，能够在视觉任务中有效捕捉到全局信息。Swin Transformer 中的自注意力计算为：

$$\mathbf{A} = \text{Softmax} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} \right) \mathbf{V} \quad (4)$$

5.2.3 微调阶段与多模态特征融合

在微调阶段，通过提示微调与多模态特征融合的方式，使得模型能够更好地利用初步的气象特征与视觉特征进行联合优化。通过对模型的权重进行更新，使得图像和气象特征能够在同一空间中进行交互。

提示微调: 利用提示信息来调整网络的某些层，从而提高模型在特定任务中的表现。微调的目标函数为：

$$\mathcal{L}_{\text{finetune}} = \lambda_1 \mathcal{L}_{\text{cross-entropy}} + \lambda_2 \mathcal{L}_{\text{regression}} \quad (5)$$

多模态特征融合: 通过将视觉特征与气象特征进行融合，利用早期交互方式提高模型的整体表现。特征融合可以表示为：

$$\mathbf{f}_{\text{fused}} = \text{Concat}(\mathbf{f}_{\text{visual}}, \mathbf{f}_{\text{weather}}) \quad (6)$$

5.2.4 基线模型与消融实验设计

基线模型包括经典的卷积神经网络 ResNet-50 和 Transformer 架构 ViT，用于对比实验：

1、**ResNet-50:** 一个传统的深度学习架构，采用残差连接来解决深度网络训练中的梯度消失问题。

2、**Vision Transformer:** Transformer 架构的视觉变体，通过将图像划分为多个 patch 进行处理，能够有效捕获长程依赖关系。

消融实验将验证自监督预训练与主干网络选择对模型表现的影响。主要实验包括：

1、**有/无预训练:** 通过比较模型在有自监督预训练与无自监督预训练情况下

的表现，验证预训练阶段对模型性能的贡献。

2、主干网络选择：通过比较 ConvNeXt V2 与 Swin Transformer 作为主干网络时的表现，分析两者在任务中的优劣。

5.3 果实病害阶段视觉识别与量化求解结果

本研究所使用的配置为 14900kf+4080s，通过 PyCharm 开发环境构建 Python3.9 训练解释器进行模型训练。基于前文的分析，本研究运用建立的模型进行求解，最终得到结果如下：

表 5.1 模型训练总汇

模型	设定	骨干	Acc	F1	Kappa	最佳轮次
HybridModel	SimCLR-SSL	ConvNeXt	1	1	1	10
HybridModel	Scratch	Swin	1	0.999	0.9988	13
HybridModel	Scratch	ConvNeXt	0.977	0.9745	0.9658	57
HybridModel	BYOL-SSL	ConvNeXt	0.985	0.9829	0.9774	70
HybridModel	SimCLR-SSL	Swin	0.991	0.9893	0.9856	50
HybridModel	BYOL-SSL	Swin	0.989	0.9871	0.9832	50
ResNet50 基线	Scratch	—	0.955	0.9518	0.9369	54
ViT-B/16 基线	Scratch	—	0.962	0.9597	0.9486	49

基于表 5.1 所示的模型训练结果，本研究对提出的混合 Transformer 模型与基线模型在石榴病害阶段分类任务中的性能表现进行系统性的对比分析。最佳模型参数量（#params）：89,417,731，FLOPs（约）：30.709 GFLOPs @ 224x224。实验结果显示，自监督预训练策略对模型性能提升具有显著促进作用。

在 ConvNeXt 骨干网络中，SimCLR-SSL 配置取得准确率、F1 分数和 Kappa 系数均为 1.000 的完美分类性能，相较随机初始化训练（Scratch）的 0.977 准确率提升了 2.3 个百分点。同样，在 Swin 骨干网络中，SimCLR-SSL 配置（0.991）相比随机初始化（1.000）在 F1 分数和 Kappa 系数上表现更为均衡，体现更好的泛化能力。BYOL-SSL 方法在两个骨干网络中介于随机初始化和 SimCLR-SSL 之间（ConvNeXt: 0.985, Swin: 0.989），可见基于预测机制的自监督学习在该任务中虽然有效，但略逊于基于对比学习的 SimCLR 方法。

从骨干网络的选择来看，Swin Transformer 在随机初始化条件下表现出卓越的性能（准确率 1.000），显著优于 ConvNeXt（0.977）。基于窗口自注意力机制的 Swin 架构在捕捉局部病害特征方面的优势，其分层设计能够有效建模不同尺度的病理特征。当引入自监督预训练后，ConvNeXt 骨干在 SimCLR-SSL 配置下达到最优性能，卷积神经网络架构在经过充分的表征学习后，在图像分类任务中具有强大竞争力。

与传统的 ResNet50 和 ViT-B/16 基线模型相比，本研究提出的混合 Transformer 模型在各项评估指标上均展现出明显优势。最优配置的混合模型（SimCLR-SSL + ConvNeXt）相比最佳基线模型（ViT-B/16）在准确率上提升 3.8 个百分点，在 Kappa 系数上提升了 5.14 个百分点。

综合各项指标，SimCLR-SSL 与 ConvNeXt 骨干的组合在本研究中表现最为优异，不仅在分类准确性上达到完美，在训练效率上也显著优于其他配置。本研究将最佳模型命名为基于自监督学习的多模态融合网络(Self-Supervised Fusion Network, SSF-Net)，以下简称模型，对此进行进一步分析得到：




图 5.1 Self-Supervised Fusion Network 训练结果

在最佳模型的训练过程中，我们观察到典型的快速收敛与稳定泛化特性。如图 5.1 所示，训练损失在前 10 个训练周期内迅速下降并趋近于零，同时验证集准确率在第 10 个周期即达到接近 1.0 的饱和状态，并在后续训练中保持稳定平台。学习率遵循余弦退火调度策略，从初始值 5×10^{-5} 单调衰减至接近零。自监督预训练 (SimCLR) 为模型使特征空间在监督微调初期即具备良好的线性可分性。验证准确率在整个训练过程中保持高位稳定，仅在第 15、18 和 28 周期附近出现轻微瞬时波动，模型对数据增强引入的分布扰动具有较高判断。




图 5.2 Self-Supervised Fusion Network 混淆矩阵

从图 5.2 混淆矩阵可以看出，模型在三个病害阶段分类任务中表现完美，对角线元素全为非零值，非对角线元素全为零，这表明模型能够清晰地区分不同病害发展阶段的特征模式。混淆矩阵结果表明，本研究提出的 SSF-Net 模型在石榴病害阶段分类任务中达到了理论上的最优性能。

表 5.2 SSF-Net 模型分类报告

类别/平均	precision	recall	f1-score	support
健康期	1	1	1	155
初发期	1	1	1	150
发病期	1	1	1	95
accuracy	1	1	1	1
macro avg	1	1	1	400
weighted avg	1	1	1	400

从分类报告同样可见，模型在各个评估指标均达到最佳标准。最后本研究使用该模型求解任务一所需表格，部分结果如下：

表 5.3 SSF-Net 模型求解结果 result1.xlsx（部分）

周数	果实编号	果实阶段
week_01	10_1	健康期
week_01	10_10	健康期
week_01	10_11	健康期
week_01	10_12	健康期
week_01	10_13	健康期
week_01	10_14	发病期
week_01	10_15	健康期
week_01	10_16	发病期
week_01	10_17	发病期
week_01	10_18	发病期
week_01	10_19	健康期
week_01	10_2	健康期
week_01	10_22	健康期
week_01	10_3	健康期
week_01	10_4	健康期
week_01	10_5	健康期
week_01	10_6	健康期
week_01	10_7	健康期
week_01	10_8	健康期
week_01	10_9	健康期

注：由于数据较多，本研究在论文中只展示部分结果，完整结果读者可查看支撑材料。

6 任务二的模型建立与求解

6.1 果实病害阶段与气象因子的定量关系建模

本研究的任务二聚焦于定量刻画气象因子对“健康期→初发期→发病期”演化过程的影响。本研究的因变量为任务一中得到的果实病害阶段，通过多维气象因子的影响进行建模。对于本任务，简要介绍有序 Logit 回归即可。有序 Logit 回归（Ordered Logit）被选为主模型，旨在检验气象因子对病害阶段演化的影响，并假设不同气象因子在病害阶段的演化过程中具有比例优势假设。有序 Logit 模型公式如下：

$$\text{logit}(P(Y \leq j)) = \alpha_j - \beta X$$

(1)

模型评估时，报告的关键统计量包括系数、置信区间、边际效应等，边际效应可以通过以下公式计算：

$$\text{ME}(X_j) = P(Y = j | X) \cdot \beta_j$$

(2)

基于任务一以及上诉模型构建，即可解决相关问题。

6.2 果实病害阶段与气象因子的定量关系求解结果

对于任务二的分析，本研究首先将问题一的得到的结果，病害截断分布进行可视化，得到结果如下：




图 6.1 result1.xlsx 病害阶段分布图

图 6.1 为病害阶段的分布情况，基于对样本数据的统计分析。如图所示，健康期的样本数量最高，为 1168 例，占总样本量的约 43.9%；初发期的样本数量为 1051 例，占比约 39.5%；发病期的样本数量最低，仅为 440 例，占比约 16.5%。

表 6.1 不同病害阶段果实样本的主要气象因子特征（当周平均值）

		0	1	2
temp_mean_w0	mean	28.474	28.21	29.267
temp_mean_w0	std	0.895	0.788	0.537
rh_mean_w0	mean	54.57	51.185	58.724
rh_mean_w0	std	11.048	9.631	9.297
vpd_mean_w0	mean	1.76	1.863	1.672
vpd_mean_w0	std	0.398	0.34	0.34
precip_sum_w0	mean	0.579	0.708	2.734
precip_sum_w0	std	2.166	1.824	4.264
ghi_mean_w0	mean	761.455	817.818	810.572
ghi_mean_w0	std	105.041	68.973	104.402
wind_spd_mean_w0	mean	3.127	3.252	3.595
wind_spd_mean_w0	std	0.923	1.22	0.925
high_rh_hours_w0	mean	0	0	0
high_rh_hours_w0	std	0	0	0
high_temp_hours_w0	mean	1.171	0.069	2.618
high_temp_hours_w0	std	3.563	0.905	4.962

如表 6.1 所示，发病期的平均气温（29.3 °C）和降水量（2.73 mm）显著高于健康期，而 VPD 显著降低（1.67 kPa），病害发展与高温、高湿及降雨过程密切相关。光照和风速变化较小，表明其作用有限。总体上，病害从健康→初发→发病阶段的演进，与气温升高、空气湿润（低 VPD 与高 RH）、降水增强密切相关；高温高湿交互环境是病害快速扩展的典型气象条件。光照与风速影响较弱。




图 6.2 关键气象特征箱线图

结合图 6.2 来看高温高湿并伴随强辐射和降水的气象条件更有利于病害暴发。




图 6.3 显著特征 $|\rho|$ 条形图

如图 6.3 所示，经 Spearman 相关分析并经 FDR 校正后，共检测到 28 个显

著气象特征($FDR \leq 0.05$)。其中, week、ghi_max_w0、dewpt_min_l1、temp_mean_l1等特征的 $|\rho|$ 值较高,病害阶段的进展与时间推移、光照强度及空气湿润程度密切相关。滞后 1–2 周的温度和露点指标显著性强于当周,提示病害过程存在气象滞后响应。整体上,高温、高湿、低蒸汽压差和较强辐照条件均有利于病害的加重,与后续多变量模型的结果一致。

表 6.2 病害阶段与气象因子的单变量相关分析

特征名称	时间	Spearman ρ	p 值	FDR 显 著性	解释
week	—	0.34	<0.001	***	病害阶段随时间显著递进
temp_mean_l1	前 1 周	0.31	<0.001	***	高温促进病害发展
dewpt_mean_l1	前 1 周	0.29	<0.001	**	空气湿润度上升有利病害
ghi_max_w0	当周	0.27	0.002	**	光照强度升高加快果升温
vpd_min_l2	前 2 周	-0.26	0.004	**	空气干燥度下降促进病害
precip_sum_w0	当周	0.25	0.006	**	降水增加利于病原传播
dewpt_min_l1	前 1 周	0.24	0.008	**	夜间湿度高促进侵染
ghi_mean_w0	当周	0.23	0.01	*	高辐照对病害有正效应
temp_max_l1	前 1 周	0.22	0.012	*	高最高温度加快病害进展
dhi_mean_l2	前 2 周	0.21	0.015	*	滞后光照累积效应
vpd_mean_l1	前 1 周	-0.20	0.02	*	空气越湿病害越严重
ghi_min_l2	前 2 周	0.19	0.025	*	持续光照波动影响微气候
dewpt_max_w0	当周	0.18	0.031	*	当周露点高利于病害扩展
wind_spd_mean_w0	当周	0.17	0.045	*	轻度风速促进孢子扩散
temp_min_w0	当周	0.16	0.048	*	高夜温减少病害抑制效应

*** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$ 。

注: 仅列出 $FDR \leq 0.05$ 的显著特征; w0 表示当周, l1/l2 表示滞后 1/2 周。
如图 6.3 和表 6.2 所示, Spearman 秩相关分析表明病害阶段与时间、温湿度及辐照特征呈显著相关($FDR \leq 0.05$)。其中, 周次 (week) ρ 值最高 ($\rho \approx 0.34$), 反映病害的时序进展性; 前 1 周平均温度 (temp_mean_l1) 和露点温度 (dewpt_mean_l1) 亦显著正相关, 提示病害发展存在气象滞后效应。VPD 最小值 (vpd_min_l2) 与病害阶段显著负相关, 空气越湿润越有利于病害加重。

为进一步量化气象因子对病害阶段的综合影响, 本研究分别构建多项 Logit 模型和 LightGBM 模型, 并采用五折分组交叉验证进行评估, 具体可见支撑材料 json 文件。

- (1) 多项 Logit 模型的总体准确率为 0.888, 宏平均 F1 值为 0.843, 加权 Kappa 系数 (QWK) 达到 0.896。。
- (2) LightGBM 模型的性能进一步提升, 准确率为 0.918, 宏平均 F1 值为 0.877, QWK 达到 0.919。




图 6.3 LightGBM 特征重要性

用于 LightGBM 模型精度较高，本研究选择 LightGBM 进行特征分析，图 6.3 可见，温度、露点及蒸汽压差为主导气象因子，高温高湿环境显著促进病害阶段的推进，与单变量分析结果一致。

综合分析结果表明，果实病害阶段的演进主要受高温高湿气候驱动。当气温持续升高且蒸汽压差（VPD）降低时，病害阶段显著递进，露点温度与降水的增加进一步促进病害扩展。前 1-2 周的气象条件对当前阶段具有显著滞后效应。多项 Logit 与 LightGBM 模型的高拟合精度验证气象因子对病害进展的解释力，其中温度、露点和蒸汽压差为关键气象驱动因子。

7 任务三的模型建立与求解

7.1 基于多模态数据的病害阶段预测模型构建

在任务三中，本研究提出一种知识蒸馏增强的跨模态时序 Transformer 架构，用于基于视觉与气象数据的果实病害阶段预测。模型设计多模态融合、时序建模增强、动态课程学习、以及不确定性量化多个关键创新点。

7.1.1 多模态融合与交叉注意力机制

在本任务中，模型的关键部分是多模态数据的融合，特别是在视觉特征和气象特征之间进行深度交互。该部分通过引入多头交叉注意力机制来实现视觉信息和气象信息的相互作用。

交叉注意力机制能够使得模型在处理视觉特征与气象特征时，能同时关注图像和气象数据中不同部分的关联性。具体而言，对于输入的视觉特征 V 和气象特征 W ，交叉注意力计算如下：

$$A = \text{Softmax} \left(\frac{Q_V K_W^T}{\sqrt{d_k}} \right) V_W \quad (1)$$

$$\mathbf{A}_W = \text{Softmax} \left(\frac{\mathbf{Q}_V \mathbf{K}_W^\top}{\sqrt{d_k}} \right) \mathbf{V}_V \quad (2)$$

最终得到的交叉注意力矩阵 A 和 A_W 表示了视觉与气象数据之间的相互影响。

通过多头注意力机制，能够在不同的子空间中捕获多样化的跨模态关系。

7.1.2 视觉-语言 Transformer (VL-T5) 设计思想

在多模态融合阶段，气象数据被视为“文本”序列进行处理，这一设计思想来源于视觉-语言 Transformer (VL-T5)。气象数据通过嵌入层转换为一个文本式的序列，然后与视觉数据一起进入跨模态 Transformer 模型。气象特征被编码为序列信息，以便于与视觉特征一同处理。假设气象数据序列为 $\mathbf{W} = [w_1, w_2, \dots, w_T]$ ，视觉特征为 $\mathbf{V} = [v_1, v_2, \dots, v_T]$ ，通过 Transformer 网络中的自注意力机制进行编码，生成共享表示 Z ：

$$Z = \text{Transformer}(V, W) \quad (3)$$

在此过程中，视觉数据与气象数据通过共享的注意力权重进行交互，生成一个融合的表达 Z ，作为后续时序建模的输入。

7.1.3 增强局部时序模式捕捉能的时序建模

在时序建模部分，本研究在标准 Transformer 模型的基础上，引入时间卷积网络 (TCN) 模块，以增强局部时序模式的捕捉能力。传统的 Transformer 模型在时序数据中对局部依赖关系的捕捉较弱，而 TCN 能够通过卷积操作有效提取时序数据中的短期依赖关系。TCN 的卷积操作定义如下：

$$\mathbf{y}_t = \text{Conv1D}(\mathbf{x}_t) = \sum_{i=0}^k \mathbf{w}_i \cdot \mathbf{x}_{t-i} \quad (4)$$

通过堆叠多个卷积层和跳跃连接，TCN 能够捕捉不同时间尺度下的依赖关系，特别是短期时序模式。

将 TCN 模块与 Transformer 模型结合，最终形成一个可以同时捕捉局部时序模式与全局依赖关系的混合时序模型。标准 Transformer 中的自注意力机制处理全局依赖，而 TCN 模块则通过卷积操作处理局部依赖。该组合使得模型在时序建模中具有更强的灵活性。

为量化模型的不确定性，本研究结合蒙特卡洛 Dropout 与贝叶斯神经网络进行双重不确定性量化。通过在预测过程中启用 Dropout，并进行多次前向传播，来估计模型的不确定性。在每次前向传播时，模型的输出为：

$$\hat{y} = \frac{1}{N} \sum_{i=1}^N f(\mathbf{x}; \theta_i) \quad (5)$$

这种方式可以为每个预测结果提供一个不确定性量化值，以衡量模型对特定预测的信心水平。

7.2 病害阶段预测模型的求解




图 7.1 模型的训练与验证性能曲线

图 7.1 给出了基于多模态融合模型的训练过程性能变化趋势，左侧为训练与验证损失曲线，右侧为训练与验证准确率曲线。模型在训练过程中表现出良好的收敛性与稳定性。在损失函数变化上，训练损失随迭代次数快速下降，并在后期保持较低水平，模型参数逐步趋于稳定。验证损失总体呈下降趋势。波峰主要出现在训练中期，与样本中果实发病阶段差异较大有关。整体上，验证损失未出现持续上升趋势，模型在训练集与验证集之间未出现明显的过拟合现象。从准确率变化趋势看，训练与验证准确率均随训练轮次持续上升，并在约第 70 轮后趋于平稳，最终验证准确率稳定在 0.90，训练准确率同样达到 0.91。两者之间的差距较小，模型在不同数据集上具有较强的泛化能力。验证准确率在早期快速提升，模型能够较快捕捉病害阶段的主要判别特征；后期的持续微幅上升反映出模型在细粒度特征上的学习逐渐深入。

综合两组曲线，模型在训练过程中实现了较好的优化效果。损失函数的稳定收敛与准确率的同步提升表明，网络的特征提取模块、跨模态注意力机制及时序卷积结构协同发挥作用。视觉编码器有效捕捉果实表面病斑的形态变化，气象特征模块提供温度、湿度及辐射等外部环境条件的动态约束，跨模态注意力层则实现两类特征之间的关联映射，从而提升整体预测精度。




图 7.2 气象特征对石榴病害阶段预测的重要性分析

图 7.2 为预测模型中气象特征的重要性得分排序结果。结果显示，相对湿度（rh）与风速（wind_spd）在病害预测中具有最高的重要性得分，分别达到 0.375 与 0.302，远高于其他气象变量。湿度与空气流动条件对果实病害的发生与发展具有显著影响。太阳辐射（solar_rad）和能见度（vis）的重要性得分分别为 0.106 0.050，处于次要但仍具有影响的水平。辐射强度的变化通常与果实表面温度及光照强度相关，总体来看，相对湿度与风速被识别为驱动果实病害时序演化的主要外部气象因子，该结果与果树病理学研究中关于“高湿环境促进病害扩散”的结论相一致，可见本研究所提出的多模态融合模型在识别病害关键环境因素有效。




图 7.3 病害阶段预测的混淆矩阵

图 7.3 为本研究所提出的预测模型在测试集上的混淆矩阵，模型对健康期、初发期、发病期三种病害阶段的分类性能，从混淆矩阵可以看出，模型的预测准确性较高。初发期预测中的大部分样本被正确分类，虽然有一些预测为发病期，但这些偏差相对较小。在该发病期样本中，预测精度最高，其中 106 个样本中的 97 预测结果与实际标签完全一致。健康期的预测完全正确。

最后，按照任务三需求，本研究给出部分预测结果表，完整结果请读者查看支撑材料：

表 7.1 任务三预测结果（部分）

果实编号	周数	病害阶段	p_健康期	p_初发期	p_发病期
10_20	week_11	初发期	0.003648165	0.836770535	0.159581259
10_20	week_12	发病期	0.003324273	0.293227524	0.703448236
10_20	week_13	发病期	0.001433836	0.006963105	0.991603076
10_20	week_14	发病期	0.003217326	0.180824608	0.815958142
10_21	week_11	发病期	0.003644513	0.460406691	0.535948873
10_21	week_12	发病期	0.003320351	0.134280458	0.86239922
10_21	week_13	发病期	0.001533758	0.007039169	0.991427064
10_21	week_14	发病期	0.003096002	0.111701891	0.88520211
1_20	week_11	初发期	0.003881487	0.567539632	0.428578913
1_20	week_12	发病期	0.0034046	0.157355025	0.839240432

8 任务四的模型建立与求解

8.1 基于生成对抗网络与形态学分析结合的病害检测框架

本任务的核心是生成对抗网络（GAN）与形态学分析结合的混合检测框架，用于异常检测和病害检测。该框架结合半监督 GAN 异常检测和 U-Net 分割网络，通过深度学习与传统图像处理方法的融合，实现异常检测与精细边缘分割的高效结合。

8.1.1 基于半监督 GAN 的异常检测框架

在异常检测阶段，采用半监督生成对抗网络（Semi-Supervised GAN）来训练生成器和判别器。生成器的任务是重构正常样本，判别器则负责区分正常样本与异常样本。在此过程中，生成器通过学习正常样本的分布来生成与真实正常样本相似的伪造图像。生成器的损失函数可以表示为：

$$\mathcal{L}_{\text{gen}} = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log(1 - D(G(x)))] \quad (1)$$

判别器的目标是区分真实样本和生成样本，因此判别器的损失函数为：

$$\mathcal{L}_{\text{dis}} = -\mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] - \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (2)$$

生成器和判别器通过对抗训练逐步优化，最终生成器能够生成与真实样本非常接近的样本，而判别器则能够较好地地区分正常与异常样本。为提高 GAN 模型的鲁棒性，结合自编码器计算重构误差作为辅助异常指标。自编码器通过将输入样本压缩成低维表示，并重建原始输入图像，计算重构误差作为异常评分。自编码器的损失函数为：

$$\mathcal{L}_{\text{auto}} = \|x - \hat{x}\|_2^2 \quad (3)$$

重构误差较大的样本被视为异常样本。结合 GAN 模型的异常分数与自编码器的重构误差，可增强异常检测的能力。

8.1.2 基于 U-Net 的边缘分割与线性特征提取

为对病害进行精准的边缘分割，本研究使用 U-Net 架构，该网络采用编码器-解码器结构，能够有效地提取图像的精细边缘信息。U-Net 的基本架构包括多个卷积层、池化层以及跳跃连接。在分割任务中，U-Net 通过跳跃连接将编码器提取的特征直接传递给解码器，增强了分割的精度。U-Net 的损失函数通常使用交叉熵损失来衡量分割结果与真实标签的差异：

$$\mathcal{L}_{\text{seg}} = -\sum_{i=1}^N (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)) \quad (4)$$

在图像的形态学分析中，使用 Canny 边缘检测与霍夫变换来提取图像中的线性特征。Canny 边缘检测的目标是检测图像中的边缘信息，具体计算过程如下：

- 1、通过高斯滤波平滑图像，减少噪声。
- 2、计算图像的梯度，得到边缘的方向和强度。
- 3、进行非极大值抑制，精确定位边缘。
- 4、应用双阈值策略确定最终的边缘。

霍夫变换用于从图像中的边缘信息中提取直线特征。其基本公式为：

$$\rho = x \cos(\theta) + y \sin(\theta) \quad (5)$$

8.1.3 融合多个异常指标

在决策阶段，模型结合来自 GAN 异常分数、自编码器重构误差和形态学线性度评分的多个异常检测指标。具体融合方法采用自适应阈值方法，通过对每个样本的多个评分进行加权，判断该样本是否属于异常类别。

融合后的决策公式为：

$$\hat{y} = \text{sigmoid}(\alpha_1 \cdot \text{GAN_score} + \alpha_2 \cdot \text{AE_score} + \alpha_3 \cdot \text{Morph_score}) \quad (6)$$

自适应阈值根据训练过程中模型的表现自动调整，确保最终判断的准确性。为每个果实构建“机械损伤分数”

对一张果实图片，经过上述过滤后通常还会剩下 0~若干个“划痕连通域”。可以定义一个机械损伤分数：

$$S_{\text{scratch}} = \sum_i \frac{L_i}{D} \cdot f(AR_i) \quad (7)$$

再定义一个病斑/非线性异常的分值：

$$S_{\text{disease}} = \frac{\text{大面积非线性异常区域面积}}{\text{果实总面积}} \quad (8)$$

判断规则：

若 $S_{\text{scratch}} > T_s$ 且 $S_{\text{disease}} < T_d$ ， $\rightarrow$ 判定为“浅层机械损伤且无病害”；否则视为无机械损伤或病害主导，不记入任务四结果。

8.2 生成对抗网络与形态学分析结合的疾病检测框架求解

通过上诉模型构建，由于篇幅有限，本研究直接对结果进行求解，得到结果如下：




图 8.1 异常检测框架相关结果分布情况

左上图给为所有 2659 个果实样本的划痕分数直方图。整体呈右偏分布，大多数样本集中在较低分数区间，绝大部分果实表面不存在明显线性细长结构，随着分数增大，样本数量单调递减，仅有少量样本分布在高分段，这些样本被模型认为存在明显的线性异常纹理；图中的虚线为使用全体样本 70% 分位数得到的自

适应阈值 T_s ，其右侧区域被定义为划痕高分样本候选集。从分布形态可以看出，划痕分数具有良好的长尾特性，大部分正常果实被压缩在低分段，只有少数疑似机械损伤样本被拉伸到高分尾部，有利于通过单一阈值 T_s 对划痕样本进行区分。




图 8.2 石榴果实浅层机械损伤样例一及其注意力响应 (week 8, 8_3)

图 8.2 左侧原始图像中，果实中下部出现一条近似带状区域，该区域由多条细小、近乎平行并呈交叉分布的浅色线纹组成，形态上符合任务四中“线性、细长、呈随机分布的浅层机械损伤”的描述。该区域周围果皮颜色基本连续，没有明显坏死、霉层或凹陷等典型病害特征，与“非病害的浅层机械损伤”先验高度吻合。

右上角机械损伤注意力图显示，模型的高响应区域（红黄区域）精确地覆盖在这条带状划痕区域上，且响应中心与划痕中部高度重合；果实其他区域则保持低响应。Gabor 线结构响应成功捕捉到该区域显著的方向一致性和细长结构；自监督深度特征建模到的异常模式与传统线性滤波形成互补，使得注意力图不仅关注到划痕本身，而且可以较好地抑制背景噪声和自然色差。分数对比体现高划痕 - 低病害特征。下方柱状图显示，该样本的 Scratch Score 显著高于 Disease Score，且综合分数接近划痕分数。

这一结果表明：

模型在此样本中将线性划痕视为主导异常；病害分数被压制在较低水平，说明病害检测分支并未将果实表面的轻微色差或散在小斑点误判为大面积病斑；综合分数保持较高，保证了该样本能够在无监督阈值筛选中被识别为浅层机械损伤果实。




图 8.2 石榴果实浅层机械损伤样例二及其注意力响应 (week 10, 10_10)

图 13 可见本方法在机械损伤与局部斑点共存的复杂场景下，仍然能够保持对线性损伤区域的主导关注，并在分数层面对病害进行有效抑制，体现出较好模型性能。最后本研究对任务四所需表格进行求解并且展示部分求解结果：

表 8.1 任务四求解 result4.xlsx (部分)

周数	果实编号	周数	果实编号
1	1_16	2	10_14
1	2_15	3	1_2
1	2_3	3	3_4
1	2_7	3	4_11
1	7_34	3	4_5
1	7_40	3	7_37
2	7_19	4	1_7
2	8_13	4	2_15
2	9_21	4	7_28
2	9_9	4	7_7

注：完整表单可见支撑材料。

9 总结

本文围绕石榴果实病害的智能识别与预测，构建了一个覆盖病害阶段识别—气象关联建模—多模态时序预测—浅层机械损伤区分的完整技术体系。研究以西北干旱半干旱地区石榴园为对象，利用 14 周监测期内采集的高密度时序果实图像及微气象观测数据，在传统人工巡查难及时、客观和精细刻画病害演化的背景下，旨在为果园病害监测与精准防控提供自动化、定量化的技术路径。

在病害阶段视觉识别方面，本文提出基于 SimCLR/BYOL 自监督预训练与 ConvNeXt-Swin 混合主干的多模态融合网络 SSF-Net。通过对比学习获得高判别力视觉表征，并在微调阶段引入气象特征的早期交互，模型在三阶段病害分类任务上实现 Accuracy、F1-score 与 Kappa 均为 1.000 的性能，显著优于 ResNet-50 与 ViT 等基线网络，证明自监督预训练与混合 Transformer 架构在细粒度病斑识别中的有效性和泛化能力。

在病害-气象关系建模方面，本文以病害阶段为有序响应变量，综合利用 Spearman 秩相关、有序 Logit/多项 Logit 回归和 LightGBM 等方法，系统刻画了温度、湿度、辐照度与病害演进之间的统计关联与边际效应。结果表明，病害从健康期向初发期、发病期的演进显著受高温、高湿（低 VPD）、降水增强及较强辐射驱动，且前 1-2 周气象条件存在显著滞后影响；LightGBM 模型在该任务中的准确率达到 0.918，进一步验证了气象因子对病害进程的解释力与预测价值。

在多模态病害阶段预测方面，本文构建了知识蒸馏增强的跨模态时序 Transformer，结合多头交叉注意力、VL-T5 式“气象文本化”建模以及 TCN 局部时序卷积，实现对未来四周病害阶段的端到端预测。实验表明，该模型在验证集上的准确率稳定在 0.90 左右，对健康期和发病期的预测尤为可靠；特征重要性分析进一步指出，相对湿度与风速是驱动病害时序演化的关键外部因子，体现了多模态融合框架在识别主导环境变量方面的优势。

在浅层机械损伤检测方面，针对划痕类线性损伤缺乏标注且易与病害混淆的问题，本文提出基于自监督特征的深度异常评分与 Gabor 线结构响应融合的检测

框架。通过自动果实裁剪、深度特征空间异常图、线性度评分及多阈值决策规则，实现了对高线性-低病害样本的无监督筛选，在 2659 张图像中有效识别出一批仅存在浅层机械划痕的果实；注意力热力图显示划痕区域被精确高亮，而病斑区域响应被成功抑制，体现模型在复杂场景下的鲁棒性与可解释性。

本文将自监督学习、多模态特征融合、时序建模与异常检测有机结合，形成一套面向石榴病害识别-解析-预测-区分的系统化解决方案。所提出的方法不仅在多项任务上取得了优于传统基线的定量性能，并揭示关键气象因子及其滞后效应对病害演化的作用机制，给出浅层机械损伤与病害的有效区分策略，兼具理论创新性与应用推广价值。

未来工作可在更大尺度与多品种果树上验证模型的泛化能力，并探索在边缘计算设备上的轻量化部署与在线预警应用，为智慧果园与精准植保提供更加完善的技术支撑。

10 参考文献

- [1] 陈天奇, 柯林·斯, 穆罕默德·诺鲁齐, 等.视觉表示对比学习简单框架[J].机器学习国际会议论文集, 2020.
- [2] 格里尔 JB, 斯特鲁布 F, 阿尔特切 F, 等.自举你的潜在表示: 一种自监督学习的新方法[J].神经信息处理系统进展, 2020.
- [3] 刘泽宇, 林宇腾, 曹越, 等.SwinTransformer: 使用移位窗口的分层视觉Transformer[J].IEEE 国际计算机视觉会议, 2021.
- [4] 吴尚, 德布纳特 S, 胡睿, 等.ConvNeXtV2: 与掩码自编码器协同设计与扩展卷积网络[J].arXiv 预印本 arXiv:2301.00808,2023.
- [5] 佚名.气象因子对石榴树冻害影响的初报[J].林业实用技术, 2013,(02):136-140.
- [6] 张竞成, 杨贵军, 袁琳, 等.一种作物病害发生范围监测方法及系统: 中国, CN104089647A[P].2014-07-01.
- [7] 王威廉, 特兰 D, 费斯兹利 M.什么造就了良好的多模态融合? [J].IEEE 模式分析与机器智能汇刊, 2022,44(8):4205-4222.
- [8] 陈奕舟, 张健, 刘勇, 等.基于 Transformer 和时间卷积网络的时序预测[J].IEEE 神经网络与学习系统汇刊, 2023.
- [9] 王哲, 余琪, 沃德 TE.计算机视觉中的生成对抗网络: 综述与分类[J].ACM 计算调查, 2021,54(2):1-38.
- [10] 何建强, 张莹, 许兴.基于物联网的智慧农业监测管理系统研究[J].湖北农业科学, 2024,63(8):176.
- [11] 何恺明, 张祥雨, 任少卿, 等.图像识别中的深度残差学习[J].IEEE 计算机视觉与模式识别会议, 2016.
- [12] 多索维茨基 A, 拜尔 L, 科列斯尼科夫 A, 等.一张图像等价于 16x16 单词: 大规模图像识别的 Transformer[J].神经信息处理系统进展, 2020.

11 附录

由于代码较多，本研究仅展示部分代码（伪代码），完整代码读者可查看支撑材料。

运行环境	Pycharm 下的 Python3.9
关键算法说明 1. 自监督学习: - SimCLR: 通过对比同一图像的不同增强视图学习特征 - BYOL: 在线网络预测目标网络的特征表示，避免负样本对 2. 多模态融合: - Early Concat: 早期特征拼接，全连接层融合 - FiLM: 特征线性调制，天气特征控制图像特征变换 3. 提示调优: - 在特征序列前添加可学习提示符，引导模型适应病害分类任务 4. 双主干架构: - ConvNeXt: 现代卷积网络，捕捉局部特征 - Swin Transformer: 层次化 Transformer，建模长距离依赖 Algorithm 1: 石榴病害分析系统核心架构 # 1. 自监督预训练模块 (SSL Pre-training) Class SelfSupervisedModel: Method __init__(backbone, projection_dim): # 双分支编码器结构 self.online_encoder = create_backbone(backbone) # 在线编码器 self.target_encoder = copy.deepcopy(online_encoder) # 目标编码器(停止梯度) self.online_proj = ProjectionHead(feat_dim→hidden_dim→projection_dim) self.predict_head = ProjectionHead(projection_dim→projection_dim) # BYOL 专用 Method simclr_forward(x1, x2): # SimCLR 对比学习流程 z1 = online_proj(online_encoder(x1)) # 视图 1 特征 z2 = online_proj(online_encoder(x2)) # 视图 2 特征 loss = NTXentLoss(z1, z2) # 归一化温度缩放交叉熵损失 Return loss Method byol_forward(x1, x2): # BYOL 非对称学习流程 p1 = predict_head(online_proj(online_encoder(x1))) p2 = predict_head(online_proj(online_encoder(x2))) with torch.no_grad(): t1 = target_proj(target_encoder(x2)) # 目标网络特征 t2 = target_proj(target_encoder(x1)) loss = (MSE_loss(p1, t1) + MSE_loss(p2, t2)) / 2 update_target_network() # 动量更新目标网络 Return loss	

```

# 多模态融合分类模型 (Multimodal Fusion Classifier)
Class HybridTransformerModel:
    Method __init__(num_classes, weather_dim, backbone_type):
        # 双主干特征提取
        if backbone_type in ["convnext", "both"]:
            self.convnext = ConvNeXtV2_Base() # 卷积主干
        if backbone_type in ["swin", "both"]:
            self.swin = SwinTransformer_Base() # Transformer 主干

        # 天气特征融合模块
        self.weather_fusion = WeatherFeatureFusion(
            type = CFG["fusion"] # "early_concat" 或 "early_film"
        )

        # 提示调优模块
        self.prompt_tuning = PromptTuningModule(
            prompt_length = 5,
            hidden_dim = total_feature_dim
        )

        # 分类头
        self.classifier = MLP(
            input_dim = total_feature_dim,
            hidden_dims = [512, 256],
            output_dim = num_classes,
            dropout_rates = [0.3, 0.2, 0.1]
        )

    Method forward(x, weather_features):
        # 特征提取
        if backbone == "both":
            features = concat(convnext(x), swin(x))
        else:
            features = selected_backbone(x)

        # 天气特征融合
        if weather_features is not None:
            features = weather_fusion(features, weather_features)

        # 提示调优
        features = prompt_tuning(features)

        # 分类预测

```

```

logits = classifier(features)
Return logits, features

# 天气特征融合模块 (Weather Feature Fusion)
Class WeatherFeatureFusionModule:
    Method __init__(fusion_type, img_dim, weather_dim):
        if fusion_type == "early_concat":
            self.fc = Linear(img_dim + weather_dim → img_dim)
        else: # FiLM 融合
            self.gamma_net = Linear(weather_dim → img_dim) # 特征缩放
            self.beta_net = Linear(weather_dim → img_dim) # 特征平移

    Method forward(img_features, weather_features):
        if fusion_type == "early_concat":
            # 拼接融合: [img_feat, weather_feat] → fused_feat
            weather_expanded = expand(weather_features to match img_features)
            fused = concat(img_features, weather_expanded)
            Return self.fc(fused)
        else: # FiLM 融合
            gamma = gamma_net(weather_features) # 条件缩放
            beta = beta_net(weather_features) # 条件平移
            Return img_features * gamma + beta # 特征调制

# 提示调优模块 (Prompt Tuning)
Class PromptTuningModule:
    Method __init__(prompt_len, feature_dim):
        self.prompts = Parameter(randn(1, prompt_len, feature_dim) * 0.02)

    Method forward(features):
        # 将可学习提示符拼接到特征序列前
        batch_prompts = expand(self.prompts to batch_size)
        Return concat(batch_prompts, features along sequence_dim)

# 训练流程伪代码 (Training Pipeline)
Procedure Main_Training_Pipeline:
    # 自监督预训练
    For each epoch in SSL_epochs:
        For batch in unlabeled_data_loader:
            x1, x2 = augment(batch) # 两种数据增强视图
            if method == "simclr":
                loss = model.simclr_forward(x1, x2)
            else: # BYOL
                loss = model.byol_forward(x1, x2)
            Backward(loss) and update_parameters()

```

```
# 监督微调
Load_SSL_pretrained_weights(classification_model)
For each epoch in FineTune_epochs:
    For (images, labels, weather_data) in labeled_data_loader:
        logits, features = model(images, weather_data)
        loss = CrossEntropy(logits, labels)
        Backward(loss) and update_parameters()

# 推理预测
For test_images in prediction_data_loader:
    predictions, _ = model(test_images, weather_data)
    disease_stages = argmax(predictions)

# 多任务推理 (Multi-Task Inference)
Procedure Task1_and_Task2_Inference:
    # 任务 1: 附件 1 整包分析
    result1 = predict_folder(attachment1_folder, trained_model)
    # 任务 2: 附件 3 整包分析
    result2 = predict_folder(attachment3_folder, trained_model)
    Save_to_excel([result1, result2])
```